

Simulación de Cadenas de Markov

Introducción

Las cadenas de Markov son una herramienta matemática para modelar sistemas que evolucionan paso a paso, donde el futuro depende solo del presente y no del pasado.

La regla principal es: $P(\text{futuro} | \text{presente, pasado}) = P(\text{futuro} | \text{presente})$

Pregunta:

Un equipo de usuario (UE) dispone de hasta tres intentos para completar el procedimiento de acceso aleatorio en el Random Access Channel (RACH). Cada intento ocurre en la siguiente "Random Access Opportunity" y, de forma independiente, tiene:

- 60 % de probabilidad de éxito (el eNB responde con un Random Access Response).
- 40 % de probabilidad de colisión (otro UE eligió el mismo preámbulo).

Después de una colisión, el UE espera un back-off fijo de una subtrama y vuelve a intentarlo. Si su tercer intento también colisiona, el UE abandona el acceso (fracaso definitivo).

Definición de la cadena de Markov

Estados: S0, S1, S2, Éxito (E), Fracaso (F)

- S0: 1er intento
- S1: 2do intento
- S2: 3er intento
- E: Éxito (absorvente)
- F: Fracaso (absorvente)

```
In [12]: import numpy as np
import matplotlib.pyplot as plt
```

```
# Matriz de transición
P = np.array([
    [0, 0.4, 0, 0.6, 0],
    [0, 0, 0.4, 0.6, 0],
    [0, 0, 0, 0.6, 0.4],
    [0, 0, 0, 1, 0],
    [0, 0, 0, 0, 1]
])
```

P

```
print("Matriz de transición P:")
print(P)
print("\nCada fila representa las probabilidades de pasar a otros estados.\n")
```

Matriz de transición P:

```
[[0.  0.4 0.  0.6 0. ]
 [0.  0.  0.4 0.6 0. ]
 [0.  0.  0.  0.6 0.4]
 [0.  0.  0.  1.  0. ]
 [0.  0.  0.  0.  1. ]]
```

Cada fila representa las probabilidades de pasar a otros estados.

Resultados analíticos

Los resultados analíticos sirven como referencia para validar la simulación. Permiten analizar cómo cambian los resultados si modificas probabilidades o el número de intentos, sin necesidad de volver a simular todo.

Los resultados analíticos se obtienen considerando todos los caminos posibles que puede seguir el sistema hasta alcanzar un estado absorbente. La probabilidad de éxito se calcula sumando las probabilidades de éxito en cada intento o, de forma equivalente, restando a uno la probabilidad de fallar los tres intentos consecutivos. El número medio de intentos se obtiene como el valor esperado de la variable aleatoria "número de intentos", ponderando cada caso por su probabilidad. Finalmente, la distribución estacionaria refleja que, al tratarse de una cadena absorbente, todos los usuarios terminan en éxito o fracaso, con proporciones iguales a sus probabilidades de absorción.

```
In [13]: # Probabilidad de éxito analítica
p_success = 1 - (0.4)**3

print("Probabilidad analítica de éxito:")
print(f"P(éxito) = {p_success:.4f}")
print("Es la probabilidad de no fallar los 3 intentos consecutivos.\n")

# Número esperado de intentos
E_N = 1*0.6 + 2*(0.4*0.6) + 3*((0.4**2)*0.6 + (0.4**3))

print("Número esperado de intentos:")
print(f"E[N] = {E_N:.4f}")

p_success, E_N

labels = ["Éxito", "Fracaso", "Intentos promedio"]
valores = [p_success, 1 - p_success, E_N]

plt.figure()
```

```
plt.bar(labels, valores)

plt.title("Resultados analíticos del modelo de Markov")
plt.ylabel("Valor")
plt.xlabel("Métricas")

plt.show()
```


Probabilidad analítica de éxito:

$$P(\text{éxito}) = 0.9360$$

Es la probabilidad de no fallar los 3 intentos consecutivos.

Número esperado de intentos:

$$E[N] = 1.5600$$



Simulación

La simulación del proceso de Markov se realizó replicando el comportamiento del procedimiento de acceso aleatorio para un gran número de usuarios (al menos 10^6). Cada usuario inicia en el primer intento y, en cada paso, se genera un resultado aleatorio que determina si ocurre éxito o colisión según las probabilidades definidas (60% y 40%). En caso de colisión, el usuario avanza al siguiente intento hasta un máximo de tres, mientras que el éxito o el tercer fallo conducen a estados finales. A partir de esta simulación repetida, se estimaron métricas clave como la probabilidad de éxito, el número medio de intentos y la

proporción de usuarios en éxito o fracaso, permitiendo comparar estos resultados empíricos con los valores analíticos y validar así el modelo.

```
In [15]: N = 10**6
p = 0.6

successes = 0
attempts = []

for _ in range(N):
    for a in range(1,4):
        if np.random.rand() < p:
            successes += 1
            attempts.append(a)
            break
        elif a == 3:
            attempts.append(3)

sim_success = successes / N
sim_mean_attempts = np.mean(attempts)

print(" Resultados de la simulación:")
print(f"Probabilidad de éxito simulada: {sim_success:.4f}")
print(f"Intentos promedio simulados: {sim_mean_attempts:.4f}")
print(f"Probabilidad de fracaso simulada: {1 - sim_success:.4f}\n")


values, counts = np.unique(attempts, return_counts=True)
probabilities = counts / N

plt.figure()
plt.bar(values, probabilities)

plt.title("Distribución de probabilidad del número de intentos")
plt.xlabel("Número de intentos")
plt.ylabel("Probabilidad")
plt.xticks([1, 2, 3])

plt.show()
```

Resultados de la simulación:
Probabilidad de éxito simulada: 0.9363
Intentos promedio simulados: 1.5593
Probabilidad de fracaso simulada: 0.0637



Comparación del resultado analítico con el simulado

Se comparan la probabilidad de éxito, el número promedio de intentos y la probabilidad de fracaso obtenidos de forma analítica y mediante simulación. Los resultados muestran la divergencia entre ambos enfoques. Esto confirma que el modelo de cadena de Markov representa adecuadamente el sistema y que la simulación es consistente, validando así tanto el análisis teórico como la implementación práctica.

```
In [10]: print("Comparación Analítica vs Simulación:")
print(f"Éxito analítico:   {p_success:.4f}")
print(f"Éxito simulado:    {sim_success:.4f}\n")

print(f"Intentos esperados (analítico): {E_N:.4f}")
print(f"Intentos simulados:                {sim_mean_attempts:.4f}")

# valores analíticos
analitico = [p_success, 1 - p_success, E_N]

# valores simulados
simulado = [sim_success, 1 - sim_success, sim_mean_attempts]

labels = ["Éxito", "Fracaso", "Intentos promedio"]

x = range(len(labels))
```

```

plt.figure()

# barras Lado a Lado
plt.bar([i - 0.15 for i in x], analitico, width=0.3, label="Analítico")
plt.bar([i + 0.15 for i in x], simulado, width=0.3, label="Simulación")

plt.xticks(x, labels)
plt.ylabel("Valor")
plt.title("Comparación Analítico vs Simulación")

plt.legend()

plt.show()

```


Comparación Analítica vs Simulación:

Éxito analítico: 0.9360

Éxito simulado: 0.9361

Intentos esperados (analítico): 1.5600

Intentos simulados: 1.5593



Se compararon la probabilidad de éxito, el número promedio de intentos y la probabilidad de fracaso obtenidos de forma analítica y mediante simulación. Los resultados muestran una alta coincidencia entre ambos enfoques, con valores muy cercanos (aproximadamente 0.936 de éxito y 1.56 intentos promedio).

Esto confirma que el modelo de cadena de Markov representa adecuadamente el sistema y que la simulación es consistente, validando así tanto el análisis teórico como la

implementación práctica.

Comparación con la paradoja del cumpleaños

La dinámica de esta cadena muestra que, aunque cada intento individual tiene una probabilidad moderada de colisión (40%), la probabilidad acumulada de fallar repetidamente crece de manera rápida cuando se encadenan varios intentos. En particular, la probabilidad de colisionar tres veces seguidas es $0.4^3 = 0.064$, lo que evidencia cómo la repetición de eventos independientes amplifica el riesgo acumulado. Este crecimiento no es lineal, sino exponencial, lo que significa que pequeñas probabilidades de colisión por intento pueden convertirse en probabilidades significativas cuando se consideran múltiples oportunidades.

Este comportamiento es análogo a la paradoja del cumpleaños, donde la probabilidad de coincidencia entre personas aumenta rápidamente al agregar más participantes, incluso si el número de posibles resultados (días del año) es grande. De manera similar, en el RACH, cada intento adicional actúa como una nueva oportunidad de colisión, y al limitar el número de intentos, se observa claramente cómo esta acumulación de probabilidades influye en la probabilidad final de fracaso. Así, la cadena de Markov ilustra cómo múltiples eventos independientes pueden generar resultados globales no intuitivos debido a la acumulación probabilística.

Conclusiones

- Las cadenas de Markov son modelos probabilísticos donde el estado futuro depende únicamente del estado actual, no del pasado.
- Se representan mediante estados y probabilidades de transición, organizadas en una matriz.
- En este ejercicio se utilizó una cadena de Markov absorbente, con estados finales de Éxito y Fracaso.
- Se observa que la simulación converge hacia el valor analítico cuando el número de muestras es grande.
- A pesar de una probabilidad significativa de colisión (40%), los reintentos permiten: Alta probabilidad de éxito y Bajo número promedio de intentos
- El sistema presenta una tendencia clara hacia el estado de éxito, mostrando eficiencia en el acceso incluso con colisiones frecuentes.